

Desafio Innvestigate

Aluna: Laura Tissi Tracierra Rezende
Data: 20/05/2025

Detecção de deepfake facial

O que foi feito?


1. Uso do MNIST para aplicação do Innvestigate

2. Procura de artigos relacionados a métodos quantitativos de explicabilidade

3. Configurações iniciais da DGX

Resultados

- Innvestigate + MNIST



- Artigo sobre quantificar técnicas de explicabilidade

- Aplica um determinado modelo em um dataset;
- Usa técnica de explicabilidade;
- Segmenta a imagem em segmentos de superpixels usando o algoritmo SLIC;
- Quantifica a contribuição de cada segmento para a decisão do detector de deepfake;
- Seleciona os top k elementos que mais tiveram influência para o modelo;
- Acrescenta ruído a esses elementos;
- Avalia a acurácia do modelo sobre esses dados com ruído.

	DF			F2F			FS			NT		
Original Accuracy	0.978			0.977			0.982			0.924		
	Top 1	Top 2	Top 3	Top 1	Top 2	Top 3	Top 1	Top 2	Top 3	Top 1	Top 2	Top 3
Grad-CAM++	0.781	0.644	0.571	0.864	0.798	0.737	0.887	0.808	0.728	0.601	0.481	0.432
RISE	0.877	0.766	0.686	0.843	0.710	0.622	0.896	0.809	0.734	0.783	0.637	0.513
SHAP	0.813	0.609	0.450	0.846	0.739	0.637	0.876	0.702	0.543	0.686	0.497	0.344
LIME	0.735	0.440	0.245	0.803	0.633	0.484	0.864	0.698	0.559	0.579	0.340	0.197
SOBOL	0.750	0.591	0.490	0.816	0.653	0.512	0.874	0.703	0.574	0.621	0.417	0.313

Próximos passos

Replicar técnica de avaliação de deepfake proposto no artigo

Replicar técnica de quantificar pixels em determinada técnica de explicabilidade

Uso da DGX

Referências

01	ALBER, M. et al. iNNvestigate Neural Networks! Journal of Machine Learning Research , v. 20, p. 1–8, 2019.
02	TSIGOS, K. et al. Towards Quantitative Evaluation of Explainable AI Methods for Deepfake Detection. arXiv (Cornell University) , 29 abr. 2024.